

Text mining – 10

Named Entity Recognition (NER)



LUTHFIL KHAIRI, S.KOM, M.CS.
PROGRAM STUDI S1 INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS ANDALAS

Capaian pembelajaran matakuliah (CPMK)

Sub-CPMK-69.04: Mahasiswa menganalisis teks menggunakan teknik analisis sentimen dan ekstraksi informasi, termasuk Named Entity Recognition (NER) dan relasi antar entitas, serta menginterpretasikan hasil analisisnya. **(CPL-11, IK-11.02)**

Tujuan Pembelajaran

Setelah mengikuti materi ini, mahasiswa mampu:

- Menjelaskan konsep dan tujuan dari Named Entity Recognition (NER)
- Menguraikan jenis-jenis entitas yang dikenali oleh NER
- Membedakan pendekatan rule-based, machine learning, dan deep learning dalam NER
- Menerapkan NER menggunakan library NLP populer (spaCy, HuggingFace)
- Melakukan evaluasi model NER dengan metrik yang sesuai


Pendahuluan ke Ekstraksi Informasi (Information Extraction/IE)

Ekstraksi Informasi (Information Extraction atau IE) merupakan salah satu bidang penting dalam Pemrosesan Bahasa Alami (Natural Language Processing) yang berfokus pada pengambilan informasi terstruktur dari data tidak terstruktur. Mari kita bahas komponen-komponen penting dalam IE.

Ekstraksi Informasi adalah serangkaian teknik dan metode yang digunakan untuk mengidentifikasi, mengekstrak, dan menyusun informasi terstruktur dari teks tidak terstruktur. Tujuannya adalah mengubah data tekstual yang sulit diolah komputer menjadi format yang lebih mudah dianalisis dan diproses secara otomatis.

Sumber data tidak terstruktur yang umum diproses meliputi:

- Artikel berita
- Dokumen ilmiah dan laporan
- Postingan media sosial dan tweet
- Email dan percakapan
- Dokumen bisnis
- Data web



Sub-tugas Utama dalam Ekstraksi Informasi

- Named Entity Recognition (NER)
- Relation Extraction
- Event Extraction
- Coreference Resolution

Named Entity Recognition (NER)

Named Entity Recognition adalah proses mengidentifikasi dan mengklasifikasikan entitas bernama dalam teks ke dalam kategori yang telah ditentukan sebelumnya.

Contoh kategori entitas:

- Orang: "Joko Widodo", "Elon Musk"
- Organisasi: "Universitas Indonesia", "Google"
- Lokasi: "Jakarta", "Pulau Bali"
- Waktu/Tanggal: "21 Mei 2023", "pukul 14.30"
- Angka/Nilai: "Rp5 juta", "23%"

Contoh penerapan NER: Kalimat: "Presiden Jokowi mengunjungi Yogyakarta pada Senin lalu."
Hasil NER: [Presiden Jokowi: ORANG], [Yogyakarta: LOKASI], [Senin lalu: WAKTU]

Relation Extraction

Relation Extraction bertujuan mengidentifikasi dan mengkategorikan hubungan semantik antara entitas yang terdeteksi dalam teks.

Contoh relasi umum:

- Bekerja_di (Orang, Organisasi)
- Berlokasi_di (Organisasi, Lokasi)
- Lahir_tanggal (Orang, Tanggal)
- Memiliki (Orang/Organisasi, Objek)

Contoh penerapan Relation Extraction: Kalimat: "Ani Yudhoyono adalah istri dari Presiden SBY." Hasil: RelationExtraction(Ani Yudhoyono, SBY, PASANGAN_DARI)

Event Extraction

Event Extraction adalah proses mengidentifikasi peristiwa yang terjadi dalam teks, termasuk waktu, lokasi, pelaku, dan komponen lain dari suatu kejadian.

Komponen event:

- Jenis peristiwa
- Waktu dan lokasi
- Partisipan (pelaku, korban, saksi)
- Atribut lain (alat, hasil, penyebab)

Contoh penerapan Event Extraction: Kalimat: "Gempa berkekuatan 6.2 SR mengguncang Pulau Sulawesi pada Jumat pagi, mengakibatkan lima korban jiwa." Hasil: Event(BENCANA_ALAM, tipe: gempa, lokasi: Pulau Sulawesi, waktu: Jumat pagi, kekuatan: 6.2 SR, dampak: lima korban jiwa)

Coreference Resolution

Coreference Resolution adalah proses mengidentifikasi semua ekspresi dalam teks yang merujuk pada entitas yang sama.

Tipe coreferensi:

- Pronomina (kata ganti): dia, mereka, itu
- Anafora: pengulangan rujukan ke belakang
- Katafora: rujukan ke depan

Contoh penerapan Coreference Resolution: Kalimat: "Presiden menyampaikan pidato. Beliau sangat menekankan pentingnya pendidikan." Hasil: [Presiden] = [Beliau] (merujuk ke entitas yang sama)

Metode dan Pendekatan dalam Ekstraksi Informasi

Beberapa pendekatan utama dalam IE meliputi:

Pendekatan Rule-based

- Menggunakan pola linguistik dan ekspresi reguler
- Dibangun berdasarkan aturan yang dibuat oleh pakar
- Kelebihan: presisi tinggi untuk domain spesifik
- Kekurangan: sulit diskalakan, membutuhkan banyak pengetahuan domain

Pendekatan Statistik

- Menggunakan model probabilistik
- Contoh: Hidden Markov Models (HMM), Conditional Random Fields (CRF)
- Membutuhkan data berlabel untuk pelatihan

Pendekatan Deep Learning

- Model neural network seperti LSTM, BiLSTM-CRF
- Transformer-based models (BERT, RoBERTa, GPT)
- Kelebihan: performa tinggi, kemampuan menangkap konteks
- Kekurangan: membutuhkan data pelatihan besar

Tantangan dalam Ekstraksi Informasi

Beberapa tantangan utama dalam IE:

- **Ambiguitas Bahasa**
 - Kata dan frasa yang memiliki beberapa arti
- **Keberagaman Linguistik**
 - Variasi dalam ekspresi bahasa dan gaya penulisan
- **Domain Spesifik**
 - Terminologi khusus dalam domain tertentu (medis, hukum, teknik)
- **Bahasa Non-formal**
 - Slang, singkatan, dan bahasa tidak baku
- **Skalabilitas**
 - Menangani volume data yang besar
- **Evaluasi**
 - Pengukuran akurasi yang konsisten dan komprehensif

Named Entity Recognition (NER): Konsep Dasar

Named Entity Recognition (NER) adalah salah satu tugas fundamental dalam Natural Language Processing (NLP) yang bertujuan untuk mengidentifikasi dan mengklasifikasikan entitas bernama (named entities) dalam teks tidak terstruktur. Entitas bernama merupakan kata atau frasa yang merujuk pada objek dunia nyata seperti orang, organisasi, lokasi, ekspresi waktu, jumlah, nilai moneter, dan kategori lainnya.

Proses NER melibatkan dua tahap utama:

- **Pendeteksian** - mengidentifikasi batas-batas entitas dalam teks (di mana entitas dimulai dan berakhir)
- **Klasifikasi** - menentukan jenis atau kategori dari setiap entitas yang terdeteksi

Kategori Umum dalam NER

Kode	Jenis Entitas	Contoh
PER	Person (Orang)	Elon Musk, Joko Widodo, Marie Curie
ORG	Organization (Organisasi)	Google, Universitas Indonesia, WHO
LOC	Location (Lokasi)	Jakarta, Mount Everest, Danau Toba
GPE	Geo-political Entity	Indonesia, United States, European Union
DATE	Date (Tanggal)	17 Agustus 1945, January 2023, hari Senin
TIME	Time (Waktu)	08:45, pukul tiga sore, tengah malam
MONEY	Money (Uang)	\$50, Rp 5 juta, 10 euro
PERCENT	Percentage (Persentase)	25%, tiga perempat, 0,5%
PRODUCT	Product (Produk)	iPhone, Toyota Avanza, Windows 11
EVENT	Event (Peristiwa)	Olimpiade Tokyo, Perang Dunia II
WORK_OF_ART	Work of Art	Mona Lisa, Harry Potter, Laskar Pelangi
LAW	Law (Hukum)	UUD 1945, Pasal 33, KUHP
LANGUAGE	Language (Bahasa)	Bahasa Indonesia, English, Mandarin
MISC	Miscellaneous (Lain-lain)	COVID-19, Java, Android

Pendekatan dalam Named Entity Recognition

- Pendekatan Berbasis Aturan (Rule-based)
- Pendekatan Statistik dan Machine Learning
- Pendekatan Deep Learning

Pendekatan Berbasis Aturan (Rule-based)

Menggunakan aturan linguistik dan pola tertentu untuk mengenali entitas.

Karakteristik:

- Menggunakan pola sintaksis dan morfologis
- Memanfaatkan kamus dan gazetteers (daftar entitas bernama yang telah diketahui)
- Ekspresi reguler untuk pola tertentu
- Aturan kontekstual

Contoh aturan sederhana:

- Kata yang diawali huruf kapital dan diikuti "University" kemungkinan adalah ORG
- Kata yang didahului oleh "Mr.", "Mrs.", "Dr." kemungkinan adalah PER
- Pola "DD Month YYYY" kemungkinan adalah DATE

Pendekatan Berbasis Aturan (Rule-based)

Kelebihan:

- Tidak memerlukan data latih yang besar
- Mudah dipahami dan dimodifikasi
- Presisi tinggi untuk domain spesifik

Kekurangan:

- Sulit untuk mencakup semua variasi bahasa
- Membutuhkan banyak pengetahuan domain
- Sulit dipertahankan untuk bahasa yang kompleks

Pendekatan Statistik dan Machine Learning

Menggunakan model statistik dan algoritma machine learning untuk mempelajari pola dari data berlabel.

Teknik populer:

- Hidden Markov Models (HMM)
- Conditional Random Fields (CRF)
- Support Vector Machines (SVM)
- Decision Trees

Fitur yang umum digunakan:

- Kata itu sendiri (token)
- Prefiks dan sufiks kata
- Huruf kapital
- Fitur kontekstual (kata sebelum dan sesudah)
- Part-of-speech tags
- Informasi sintaksis

Pendekatan Statistik dan Machine Learning

Kelebihan:

- Kemampuan generalisasi lebih baik
- Dapat menangani variasi bahasa
- Lebih adaptif terhadap domain baru

Kekurangan:

- Membutuhkan data latih yang cukup besar
- Performa bergantung pada kualitas fitur yang digunakan

Pendekatan Deep Learning

Menggunakan neural networks untuk mempelajari representasi dan klasifikasi entitas.

Arsitektur populer:

- Recurrent Neural Networks (RNN)
- Long Short-Term Memory (LSTM)
- Bidirectional LSTM (BiLSTM)
- Convolutional Neural Networks (CNN)
- Transformer-based models (BERT, RoBERTa, GPT)

Fitur:

- Word embeddings (Word2Vec, GloVe, FastText)
- Contextual embeddings
- Character-level representations
- Fitur leksikal dan sintaksis

Pendekatan Deep Learning

Kelebihan:

- Kemampuan menangkap konteks jarak jauh
- Tidak memerlukan feature engineering manual
- Performa state-of-the-art

Kekurangan:

- Membutuhkan data latih yang lebih besar
- Komputasi lebih intensif
- Model biasanya kurang interpretable

Format Anotasi untuk NER

Format anotasi dalam Named Entity Recognition (NER) merupakan sistem standar untuk menandai dan merepresentasikan entitas bernama dalam teks.

Format anotasi yang baik sangat penting karena memengaruhi kualitas data pelatihan, evaluasi model, dan interoperabilitas antara berbagai sistem NER.

Fungsi Format Anotasi NER

Format anotasi NER memiliki beberapa fungsi penting:

- **Standardisasi** - Menyediakan format standar untuk merepresentasikan entitas dalam teks
- **Penandaan Hierarki** - Menandai struktur dan hubungan entitas yang kompleks
- **Pelatihan Model** - Menyediakan data berlabel untuk melatih model machine learning
- **Evaluasi** - Memungkinkan perbandingan hasil prediksi dengan anotasi gold standard
- **Interoperabilitas** - Memudahkan pertukaran data antara berbagai sistem dan tools

Format Anotasi untuk NER

1. Format IOB (Inside-Outside-Beginning)

Format IOB adalah format anotasi paling dasar dan umum digunakan dalam NER. Setiap token dalam teks diberi label sebagai berikut:

- **I-[TAG]**: Inside - Menandai token yang merupakan bagian dalam dari entitas
- **O**: Outside - menandai token yang bukan bagian dari entitas
- **B-[TAG]**: Beginning - menandai awal dari entitas bernama

Kelebihan:

- Sederhana dan mudah diimplementasikan
- Mendukung entitas multi-token
- Banyak didukung oleh tools dan library NLP

Kekurangan:

- Tidak dapat merepresentasikan entitas bertingkat (nested entities)
- Kurang ekspresif untuk kasus kompleks

Contoh:

John	B-PER
works	O
at	O
Google	B-ORG
in	O
New	B-LOC
York	I-LOC
.	O

Format Anotasi untuk NER

2. Format BIO (sama dengan IOB)

Format BIO identik dengan IOB, hanya berbeda dalam penamaan (BIO vs IOB). Penggunaannya sama persis.

Contoh:

John	B-PER
works	O
at	O
Google	B-ORG
in	O
New	B-LOC
York	I-LOC
.	O

Format Anotasi untuk NER

2. Format BILOU

Format ini merupakan ekstensi dari IOB dengan penambahan label untuk menandai akhir entitas dan entitas tunggal:

- **B-[TAG]**: Beginning - awal entitas
- **I-[TAG]**: Inside - bagian dalam entitas
- **L-[TAG]**: Last - bagian akhir entitas
- **U-[TAG]**: Unit - entitas tunggal (hanya satu token)
- **O**: Outside - bukan bagian dari entitas

• Kelebihan:

- Lebih ekspresif dan informatif dibandingkan IOB
- Lebih jelas dalam menandai batas entitas
- Dapat meningkatkan performa model NER karena informasi lebih lengkap

• Kekurangan:

- Lebih kompleks untuk diimplementasikan
- Masih tidak dapat menangani entitas bertingkat

Contoh:

Presiden	B-PER
Jokowi	L-PER
mengunjungi	O
Jakarta	U-LOC
pada	O
hari	O
Senin	U-DATE
.	O

Aplikasi Nyata Named Entity Recognition

1. Chatbot dan Asisten Digital

- Mengekstrak entitas dari pertanyaan pengguna
- Memahami konteks percakapan
- Memberikan respons yang lebih relevan dan personal

2. Penyaringan dan Analisis Informasi Berita

- Mengidentifikasi nama orang, organisasi, dan lokasi dalam berita
- Pelacakan tren dan topik berdasarkan entitas
- Analisis sentimen terkait entitas tertentu

Aplikasi Nyata Named Entity Recognition

3. Business Intelligence

- Ekstraksi nama pesaing dari artikel bisnis
- Pelacakan lokasi dan tanggal acara penting
- Analisis tren pasar berdasarkan entitas

4. Dokumen Hukum dan Medis

- Identifikasi nama obat, penyakit, dan prosedur dalam catatan medis
- Ekstraksi nama klien, hakim, dan tanggal sidang dalam dokumen hukum
- Anonimisasi data sensitif

Aplikasi Nyata Named Entity Recognition

5. Sistem Pencarian Informasi

- Peningkatan indeksasi dan retrieval
- Mendukung pencarian berdasarkan entitas
- Memungkinkan pencarian semantik

6. Sistem Rekomendasi

- Ekstraksi preferensi pengguna
- Rekomendasi berdasarkan entitas yang relevan
- Personalisasi pengalaman pengguna

7. Analisis Media Sosial

- Pelacakan merek dan produk
- Analisis tren topik dan entitas
- Deteksi peristiwa dan kejadian penting

Tantangan dalam Named Entity Recognition

1. Ambiguitas

- Kata yang sama dapat merujuk pada entitas berbeda tergantung konteks
- Contoh: "Java" bisa merujuk pada pulau, bahasa pemrograman, atau kopi

2. Entitas Baru dan Rare Entities

- Entitas yang jarang muncul dalam data pelatihan
- Entitas baru yang belum ada saat model dilatih

3. Variasi Linguistik

- Variasi penulisan nama (Jokowi vs. Joko Widodo)
- Singkatan dan akronim (PBB vs. Perserikatan Bangsa-Bangsa)
- Entitas multi-kata dan batas yang tidak jelas

Tantangan dalam Named Entity Recognition

4. Domain Spesifik

- Terminologi khusus dalam domain tertentu (medis, hukum, teknik)
- Kebutuhan adaptasi model untuk domain spesifik

5. Multilingualisme

- Perbedaan struktur bahasa dan aturan kapitalisasi
- Transliterasi nama entitas antar bahasa

6. Entitas Bertingkat (Nested Entities)

- Entitas yang terkandung dalam entitas lain
- Contoh: "Bank Indonesia" (ORG) berisi "Indonesia" (GPE)

Terimakasih!



Tugas Kelompok

Tugas Kelompok: Menerapkan NER pada Dataset Berita atau Dokumen Legal

Deskripsi Tugas

- Setiap kelompok akan mengembangkan sistem Named Entity Recognition (NER) untuk mengekstrak entitas penting dari dataset berita atau dokumen legal sesuai dengan topik . Tugas ini mencakup pengumpulan data, preprocessing, implementasi model NER, evaluasi, dan visualisasi hasil.

Tujuan Pembelajaran

- Memahami konsep dan penerapan teknik NER pada dokumen teks
- Mengembangkan keterampilan preprocessing data teks
- Mengimplementasikan dan mengevaluasi model NER
- Menganalisis dan memvisualisasikan hasil ekstraksi entitas
- Mengembangkan keterampilan kerja tim dan manajemen proyek

Tahapan Tugas

1. Pengumpulan dan Persiapan Data

- Mengumpulkan minimal 50 artikel berita/dokumen legal dalam domain yang ditugaskan
- Melakukan pembersihan dan preprocessing data
- Membagi dataset menjadi data training (70%) dan testing (30%)
- Membuat anotasi manual untuk sebagian kecil data (10-15 dokumen)

2. Implementasi Model NER

Setiap kelompok dapat memilih salah satu pendekatan berikut:

- **Pendekatan Rule Based** : Mengembangkan aturan linguisitik dan pola untuk mendeteksi entitas
- **Pendekatan Machine Learning**: Menggunakan algoritma seperti CRF, HMM, atau SVM
- **Pendekatan Deep Learning**: Mengimplementasikan model seperti BiLSTM-CRF atau BERT

Tahapan Tugas

3. Evaluasi Model

- Mengevaluasi performa model menggunakan metrik standar (Precision, Recall, F1-Score)
- Melakukan analisis kesalahan dan mengidentifikasi area perbaikan
- Mengoptimalkan model berdasarkan hasil evaluasi

4. Analisis dan Visualisasi

- Menganalisis distribusi dan frekuensi entitas yang diekstrak
- Memvisualisasikan hasil menggunakan grafik dan diagram yang sesuai
- Mengidentifikasi pola atau insight menarik dari hasil ekstraksi

5. Penyusunan Laporan dan Presentasi

- Menyusun laporan komprehensif tentang metodologi, implementasi, dan hasil
- Mempersiapkan presentasi untuk dipresentasikan di kelas

Spesifikasi Topik

Berita Politik

- **Dataset:** Artikel berita politik dari portal berita nasional
- **Fokus NER:** Entitas person (politisi), organization (partai politik, lembaga pemerintah), location, event (pemilu, sidang, dll)
- **Output Tambahan:** Analisis tokoh politik yang paling sering disebut dan hubungannya dengan organisasi

Berita Ekonomi & Bisnis

- **Dataset:** Artikel berita ekonomi dan bisnis
- **Fokus NER:** Entitas organization (perusahaan), person (eksekutif bisnis), money (nilai mata uang), percent (persentase), date
- **Output Tambahan:** Analisis tren perusahaan dan nilai keuangan yang sering muncul

Spesifikasi Topik

Berita Olahraga

- **Dataset:** Artikel berita olahraga
- **Fokus NER:** Entitas person (atlet, pelatih), organization (tim, klub), event (turnamen, pertandingan), location
- **Output Tambahan:** Analisis atlet/tim yang paling sering disebut dan keterkaitannya dengan event tertentu

Dokumen Legal

- **Dataset:** Dokumen legal (undang-undang, putusan pengadilan, kontrak)
- **Fokus NER:** Entitas person (hakim, pengacara), organization (institusi hukum), date, law (pasal, undang-undang), location
- **Output Tambahan:** Analisis referensi hukum yang paling sering dikutip dan hubungannya dengan kasus-kasus tertentu

Pembagian Kelompok

Kelompok 1 (Berita Olahraga):

Kelompok 1

- EZZA ADDINI
- FATHUR RAMADHAN FAHMI
- FIKHRI HANIF
- GHAZI FADHLULLAH

Kelompok 2 (Berita Ekonomi & Bisnis):

- IRFAN TRIANDA
- MUHAMMAD FARREL GIOVANNI
- MUHAMMAD FAWWAZ WIYOGA

Kelompok 3 (Dokumen Legal):

- MUHAMMAD LUTHFI KAUTSAR RIZATA
- MUHAMMAD RIEDHO RAMADHAN SYAFEI
- OKTAVIA RAMADANI

Kelompok 4 (Berita Politik):

- REZA SEPTIAN
- SITI FADHILAH RAHMI
- STANLEY LEONARD DARMALI
- SURYA ANDIKA